

Pesquisa e Ordenação de Dados

Unidade 3.1:

Arquivos

Dados

- **Dados transientes:** mantidos por tempo limitado durante a execução de um programa.
- **Dados persistentes:** mantidos por longos períodos de tempo, sendo acessados e processados repetidamente ao longo deste tempo.
- Em qualquer caso, os dados precisam ser armazenados fisicamente em alguma mídia de armazenamento (representação física).
- Em linguagens de programação, dados persistentes são representados em termos de registros e arquivos (representação lógica).
 - Mapeamento entre a representação lógica e a representação física é feito pelo sistema operacional (SO).


Mídias de armazenamento

- Armazenamento **primário**
 - Também chamado de **memória interna**
 - Mídias que podem ser operadas diretamente pela CPU
 - Armazenamento volátil: após desligar o computador, a informação se perde
 - Acesso rápido aos dados, mas com capacidade limitada (por ser mais cara)
 - Registradores
 - Cache: retém os dados utilizados com maior frequência pelo processador, evitando que ele tenha que buscá-los sempre na memória RAM (acelera o desempenho)
 - Memória principal (RAM): armazena temporariamente dados e programas que estão em uso

Mídias de armazenamento

- Armazenamento **secundário**
 - Também chamado de **memória externa**
 - Os dados não podem ser processados diretamente pela CPU; eles devem ser primeiro copiados para um armazenamento primário
 - Armazenamento não volátil: dados armazenados na forma de **arquivos**
 - Maior capacidade e menor custo, porém, com acesso mais lento do que o armazenamento primário
 - Discos magnéticos: discos rígidos (HD), discos flexíveis (disquetes, em desuso)
 - Memória flash: pen drive, cartão, SSD
 - Discos óticos: CDs, DVDs
 - Fitas magnéticas: acesso sequencial, mais lento, porém com menor custo. Utilizada para backups e para arquivamento de arquivos de registros históricos que são raramente acessados.

Estrutura de um disco rígido



[Sugestão de vídeo: discos magnéticos](#)

Estrutura de um disco rígido

- **Trilha:** círculos concêntricos, cada qual possuindo um diâmetro distinto, que armazenam as informações na superfície dos discos.
 - Em cada trilha, cada posição está distante do ponto de leitura/gravação, no máximo, uma rotação
- **Cilindro:** unidade formada pelas trilhas de mesmo diâmetro entre as várias superfícies de um conjunto (*pack*) de discos.
 - Dados armazenados em um cilindro podem ser recuperados mais rapidamente do que se estivessem distribuídos em diferentes cilindros
- **Setor:** divisão da trilha em unidades menores. Esta divisão é codificada na superfície do disco e não pode ser alterada.
- **Bloco ou página:** divisão de uma trilha feita pelo sistema operacional durante a inicialização (formatação) do disco.
 - Deve ser um múltiplo do tamanho de 1 setor

Blocos

- Dados precisam estar na memória principal para serem operados/manipulados
 - A transferência de dados entre a memória principal e o disco se dá em unidades de **bloco** de disco
 - Ler ou escrever um bloco = operação de Input/Output (I/O)
 - Se um único item num bloco é necessário, todo o bloco é transferido
- O endereço físico de um bloco (combinação de número do cilindro, número da trilha e número do bloco) é fornecido ao hardware de entrada e saída do disco
- O endereço de um *buffer* também é fornecido
 - *Buffer*: área contígua reservada no armazenamento principal que mantém um bloco
- Leitura: o bloco é copiado do disco para o *buffer*
- Escrita (gravação): o conteúdo do *buffer* é copiado para o bloco do disco

Tempos de acesso

- Procura (*seek time*)
 - Tempo para o cabeçote se deslocar até a trilha desejada;
- Rotação (*rotational latency*)
 - Tempo de espera para que início do bloco desejado rotacione até a posição sob o cabeçote do disco;
- Transferência (*transfer time*)
 - Tempo para ler ou escrever no bloco = tempo de rotação do bloco sob a cabeça do disco;

Sistema de arquivos

- É a parte do sistema operacional (SO) que organiza de forma lógica os dados armazenados em disco;
- Visão lógica (abstrata) do disco (por meio de arquivos e diretórios);
- Organização padrão:
 - Arquivos
 - Unidade básica de dados vista pelo usuário;
 - Diretórios
 - Sistema de classificação dos arquivos;
- Padrões de sistemas de arquivos:
 - Ext4: é o sistema de arquivos utilizado pelo Sistema Operacional Linux;
 - NTFS: é o sistema de arquivos no Windows;

Funções Básicas do Sistema de Arquivos

- Do ponto de vista do Sistema Operacional (funções de baixo nível; devem ser transparentes ao usuário):
 - Uso eficiente dos discos (escalonamento das requisições)
 - Descrição dos arquivos
 - Gerenciamento do espaço físico
 - Gerenciamento de blocos livres/ocupados
 - Detecção/correção de erros
 - Cache
 - Criptografia
 - Compressão de dados

Funções Básicas do Sistema de Arquivos

- Do ponto de vista do usuário (funções de alto nível):
 - Referenciar um arquivo pelo nome
 - Criar, apagar, mover, ler, escrever arquivos
 - Controlar o compartilhamento e os direitos de acesso
 - Manipular a estrutura de diretórios a fim de organizar seus arquivos
 - Procurar / classificar arquivos
 - Efetuar backups

Interface Usuário

Gerência de Diretórios

Núcleo de Sistema de Arquivos

Gerência de Dispositivos

Periféricos

Interface Usuário

- Chamadas de sistema (system calls):
 - Manipulação de arquivos:
 - open, close, read, write, ...
 - Manipulação de diretórios:
 - cd, mkdir, rmdir, ls, ...
- O SO estabelece o vínculo entre nome simbólico do arquivo e o lugar de armazenamento no disco;
- Para o usuário, o arquivo é caracterizado:
 - Por um nome (com ou sem extensão)
 - Por atributos
 - Por uma organização lógica

Gerência de Diretórios

- Sua função básica é “achar” o arquivo:
 - A partir de um ponto de entrada (raiz), vai identificar um caminho até o arquivo;
 - Associa ao nome do arquivo um descritor (por exemplo FILE*, na linguagem C);
 - Abre o arquivo para o usuário;

Núcleo do sistema de arquivos

- Função Básica:
 - Gerenciamento dos arquivos abertos;
 - Armazena os descritores de arquivos em estruturas de dados (tabelas associadas aos processos);
 - Cada processo tem uma tabela de arquivos abertos;
 - Mais indicações sobre o tipo de operações (Escrita, leitura...)
- Os descritores são associados a um identificador (ponteiro):

```
FILE* meu_arquivo;
```

```
meu_arquivo = fopen("arquivo.txt","r");
```

Gerência de Dispositivos

- Função básica: alocar/liberar “blocos”
 - Blocos são mapeados em setores
 - Conforme for necessário, é preciso:
 - Obter mais blocos (quando um arquivo está sendo criado ou expandido)
 - Liberar blocos (quando um arquivo está sendo removido)
- Problemas a resolver:
 - Fragmentação
 - Desempenho (tempo)
 - Bom uso do disco (alocação espaço)

Atributos de um arquivo

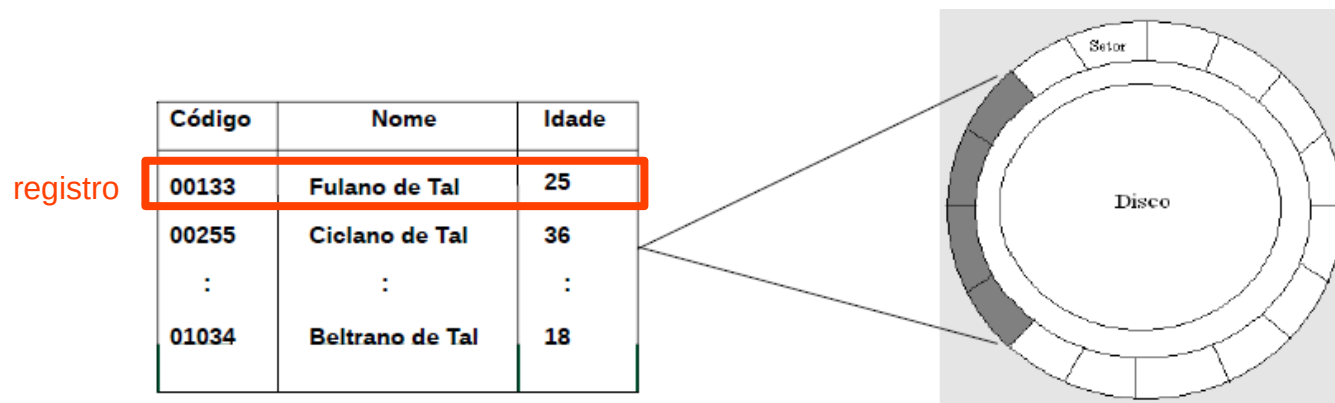
- Metadados (metadata):
 - Data de criação;
 - Tamanho;
 - Proprietário (Identificador (ID) do usuário);
 - Grupo (Identificador (ID) do grupo);
- Informações de segurança:
 - Direitos de acesso
 - r (read/leitura), w (write/escrita), x (execução)
- Tipo:
 - Arquivo, diretório, link (ligação, que permite compartilhar arquivos)

Tipos de arquivo

- Um sistema operacional suporta vários tipos de arquivos.
- O tipo condiciona as operações que podem ser efetuadas com o arquivo:
 - Execução; leitura; escrita; apenas acesso
- Exemplos:
 - Executável (binário)
 - Texto puro
 - Arquivo de dispositivo (device) no Linux
 - Diretório
- Um arquivo de um dado tipo pode ter seu acesso restrito:
 - Apenas leitura/Apenas escrita/ Apenas acesso...

Arquivos de registros

- Diversas aplicações armazenam dados na forma de **arquivos de registros**.
 - Cada registro é uma coleção de valores que podem ser interpretados como fatos a respeito de entidades, bem como seus atributos e relacionamentos.
 - Cada valor é formado por um ou mais bytes e corresponde a um **campo** de um registro.
 - Os arquivos são armazenados em vários **blocos** do disco.
- Os registros devem ser organizados de maneira que seja possível localizá-los eficientemente quando necessário.
 - Chamamos o estudo destas técnicas de **Organização de Arquivos**



Arquivos de registros

- Objetos sobre os quais se armazenam informações são chamados de **entidades**
 - Tangíveis: cliente, aluno, empregado, escola
 - Intangíveis: evento, conta corrente, centro de custos
- Um conjunto de entidades que representam objetos de mesma natureza é chamado de **classe de entidades**
 - Os empregados da empresa X
 - Os alunos da escola Y
- Entidades são caracterizadas por propriedades denominadas **atributos**
 - Nome, matrícula, profissão, departamento em que trabalha, salário, endereço, etc
- Um conjunto de pares <atributo, valor> que identifica uma entidade é chamado de **registro** de entidade

Ex: registro de um empregado

Atributo	Valor do atributo
Nome	Osvaldo Peres
Matrícula	2.044.431
Profissão	Contabilista

Terminologia

- Arquivo
 - Coleção de registros lógicos, cada um representando uma entidade
- Registro Lógico (Registro)
 - Sequência de itens de dados, sendo cada item um **campo** ou **atributo**
 - Cada **campo** representa uma característica ou propriedade, possuindo nome, tipo e tamanho (fixo ou variável)
- Registro Físico
 - Armazenamento do arquivo em **blocos de registros lógicos** chamado registro físico (leitura/gravação)
 - Tamanho do bloco coincide ou é múltiplo de uma unidade de armazenamento do meio físico (Ex.: setor)
 - Cada bloco armazena um número inteiro de registros

Terminologia

- Chave
 - Sequência de um ou mais campos de um registro
- Chave de Acesso (ou pesquisa)
 - É uma chave utilizada para identificar o(s) registro(s) desejado(s) em uma operação de acesso a um arquivo
 - Primária: valor único
- Argumento de Pesquisa
 - Valor da chave de acesso em uma operação
- Chave de Ordenação
 - É a chave primária utilizada para estabelecer a sequência na qual devem ser dispostos (física ou logicamente) os registros de um arquivo

Formato dos Registros

- Registro com tamanho **fixo**:

- Campos de tamanho fixo:

- Número de campos fixo;
 - Cada campo tem o mesmo tamanho em todos os registros;

- Campos de tamanho variável:


- Número de campos fixo;
 - Campos têm tamanhos variáveis;

- Registro com tamanho **variável**:


- Registros podem número diferente de campos.

Formato dos Registros


Tamanho fixo e campos de tamanho fixo



Tamanho fixo e campos de tamanho variável



Tamanho variável e número de campos variável



Organização de Arquivos

- Organização primária
 - Determina como os registros de um arquivo são posicionados e interligados fisicamente no disco e como eles podem ser acessados
 - Arquivo sequencial: registros são acessados na ordem em que estão fisicamente armazenados
 - Arquivo sequencial desordenado
 - Arquivo sequencial ordenado
 - Arquivo hash: acesso direto
- Organização secundária
 - Estrutura de acesso auxiliar (índice) que permite um acesso eficiente aos registros de um arquivo independentemente de sua organização primária
 - Arquivo indexado

[Sugestão de vídeo: Organização de Arquivos](#)